

1.3 — Análise Exploratória dos Dados Meteorológicos

Este notebook realiza uma análise exploratória completa dos dados do projeto Climate Intelligence Engine. O objetivo é entender a estrutura, qualidade, padrões e relações dos dados antes de qualquer modelagem.

Datasets utilizados:

- `stations.parquet` — metadados das 663 estações
- `weather_measurements.parquet` — medições horárias de 2000 a 2025
- `station_distances.parquet` — distâncias par-a-par entre estações

Ao final, o notebook é exportado automaticamente para PDF.

0. Setup

1. Carga dos Dados

```
=== Ficha Técnica do Dataset ===
Estações           : 663
Registros de medição : 83,153,626
Período            : 2000-05-07 → 2025-12-31
Anos cobertos      : 26
Pares de distância : 438,906
Estados cobertos   : 27
Altitude mín / máx : 0 m / 1790 m
```

1.1 Estatísticas Descritivas

Antes de qualquer análise visual, é fundamental entender os números centrais de cada variável. Esta seção apresenta média, desvio padrão, quartis, assimetria e curtose.

O que esperar: variáveis como temperatura e pressão devem ter distribuições próximas do normal. Chuva e radiação tendem a ser fortemente assimétricas à direita (muitas horas com valor zero ou baixo e poucos eventos extremos).


	count	mean	std	min	25%	50%	75%	max	skewness	kurtosis
Temperatura (°C)	70748950.0	23.39	5.62	-9.6	20.1	23.60	27.1	45.0	-0.34	0.40
Umidade (%)	68917440.0	71.76	20.29	7.0	58.0	76.00	89.0	100.0	-0.67	-0.45
Chuva (mm)	66941238.0	0.16	1.29	0.0	0.0	0.00	0.0	138.2	17.94	484.51
Radiação (KJ/m²)	69190117.0	831.36	1713.54	-43.0	-3.4	39.07	1457.6	51588.0	11.01	204.48
Pressão (hPa)	70683132.0	964.84	37.85	802.0	938.7	969.30	996.8	1050.0	-0.71	0.19
Ponto de Orvalho (°C)	68784392.0	17.17	4.87	-42.5	14.2	18.10	20.9	45.0	-0.95	1.69
Vel. Vento (m/s)	68260804.0	1.99	1.70	0.0	0.7	1.70	2.9	43.4	1.31	3.47
Rajada (m/s)	68207439.0	4.86	3.05	0.0	2.5	4.50	6.8	50.0	0.73	1.07
Dir. Vento (°)	67918855.0	154.01	98.35	0.0	76.0	131.00	230.0	360.0	0.51	-0.84

1.1.1 Assimetria e Curtose por Variável

Assimetria (skewness): valores próximos de 0 indicam distribuição simétrica. Valores positivos altos indicam cauda longa à direita (ex: chuva). Valores negativos indicam cauda à esquerda.

Curtose: mede o 'pico' da distribuição. Valores altos indicam distribuições leptocúrticas (pico agudo, caudas pesadas), como pode ocorrer em rajadas de vento e chuva intensa.

O que esperar: `rainfall` e `global_radiation` devem ter assimetria muito alta. `temperature` e `pressure` devem ser próximas de zero.




1.1.2 Distribuição de Cada Variável — Histograma + KDE

Visualiza a forma da distribuição de cada variável meteorológica. A linha KDE (Kernel Density Estimate) suaviza o histograma e facilita identificar bimodalidade, skew e outliers.

O que esperar: temperatura deve ter forma aproximadamente gaussiana com possível bimodalidade regional. Chuva e radiação solar devem ter pico em zero e longa cauda à direita.

Distribuição das Variáveis Meteorológicas (p1–p99)



1.1.3 Boxplots por Variável

O boxplot mostra mediana, IQR (intervalo interquartil), mínimo/máximo e outliers de forma compacta. É especialmente útil para comparar a dispersão e a presença de valores extremos entre variáveis.

O que esperar: `wind_gust`, `rainfall` e `global_radiation` devem ter muitos outliers superiores, dado seu caráter episódico (eventos extremos pontuais).


Boxplots das Variáveis Meteorológicas



1.1.4 Evolução do Volume de Dados ao Longo do Tempo

Mostra quantos registros não-nulos existem por ano em cada variável. Permite identificar quando a rede de estações se expandiu, períodos de falha generalizada e possíveis problemas de coleta em anos específicos.

O que esperar: crescimento gradual do volume até ~2015 com a expansão da rede INMET, seguido de estabilização. Quedas abruptas indicam falhas sistêmicas ou mudanças no protocolo de coleta.




2. Qualidade dos Dados

Antes de usar os dados para modelagem ou análise, é essencial entender onde e quanto falta. Esta seção quantifica os dados ausentes, inconsistências físicas e cobertura temporal por estação.

2.1 Taxa de NaN por Variável

Percentual de valores ausentes em cada variável sobre o total de registros. Verde = menos de 10% faltante (aceitável), laranja = 10–30% (requer atenção), vermelho = acima de 30% (crítico).


O que esperar: `global_radiation` e `wind_direction` tendem a ter mais NaN por serem sensores com maior taxa de falha. `temperature` e `pressure` costumam ser os mais completos.



2.2 Taxa de NaN por Estação — Top 30 Piores

Identifica quais estações têm maior proporção de dados ausentes, considerando a média de todas as variáveis. Estações com alta taxa de NaN podem precisar ser excluídas ou tratadas com cautela em modelos.


O que esperar: estações mais recentes (inauguradas após 2015) ou em regiões remotas costumam ter menos dados simplesmente por terem operado por menos tempo.



2.3 Heatmap de NaN — Estação × Variável

Mostra simultaneamente quais variáveis e quais estações têm mais dados faltantes. Padrões horizontais (uma estação ruim em todas as variáveis) indicam estação com problema geral. Padrões verticais (uma variável ruim em todas as estações) indicam sensor com falha sistêmica.

O que esperar: padrões mistos, com algumas estações ruins em todas as variáveis e algumas variáveis consistentemente piores.




2.4 Cobertura Temporal por Estação

Mostra a distribuição de quantos anos cada estação possui dados e quando cada uma começou a operar. É importante para entender se uma estação com poucos dados é nova ou sofreu interrupção.

O que esperar: pico de inaugurações entre 2007 e 2012 (expansão da rede INMET automática).

Poucas estações com cobertura superior a 20 anos.




2.5 Padrão Temporal de Dados Faltantes por Estação

Mostra a completude de `temperature` mês a mês para cada estação ao longo de toda a série histórica. Diferente do heatmap estático (2.3), este revela **quando** os gaps ocorrem: se são blocos contínuos de meses/anos ou falhas isoladas.

Esta análise é essencial para o gap-filling: um gap de 2 horas pode ser preenchido por interpolação, enquanto um gap de 6 meses exige estações proxy.


O que esperar: estações mais antigas com dados desde 2000. Estações novas com bloco vermelho no início (antes de entrarem em operação). Algumas estações com interrupções longas no meio da série, indicando paradas de manutenção ou falha de equipamento.



2.6 Detecção de Outliers Físicos

Verifica quantos registros estão fora de limites fisicamente plausíveis para o Brasil. Esses valores não são apenas extremos estatísticos — são impossíveis ou altamente improváveis do ponto de vista meteorológico e indicam erros de sensor ou de entrada de dados.

O que esperar: poucos outliers físicos na maioria das variáveis. Umidade acima de 100% ou abaixo de 0% é um erro claro. Pressões abaixo de 700 hPa ou acima de 1100 hPa são impossíveis ao nível do mar.



2.7 Consistência entre Variáveis

Verifica regras físicas que devem sempre ser verdadeiras:

- O ponto de orvalho (`dew_point`) nunca pode ser maior que a temperatura do ar (`temperature`).
- A rajada (`wind_gust`) sempre deve ser maior ou igual à velocidade média (`wind_speed`).

O que esperar: pequena porcentagem de violações — geralmente abaixo de 1–2%. Valores altos sugerem necessidade de limpeza antes da modelagem.

Registros analisados	: 66,141,574
Violações <code>dew_point > temperature</code>	: 36,480 (0.06%)
Violações <code>wind_gust < wind_speed</code>	: 61 (0.00%)


3. Análise Geoespacial

Entender onde as estações estão localizadas e como se distribuem geograficamente é essencial para avaliar a cobertura da rede e identificar regiões com lacunas de dados.

3.1 Distribuição de Estações por Estado

Quantidade de estações meteorológicas por unidade federativa.


O que esperar: Minas Gerais, São Paulo, Mato Grosso e Pará provavelmente lideram. Estados menores do Nordeste e Sul podem ter menos estações.



3.2 Distribuição de Altitude

Histograma das altitudes de todas as estações.

O que esperar: maioria das estações entre 0 e 1000 m. Pouquíssimas acima de 1500 m.




```
count    663.0
mean      409.7
std       335.1
min        0.0
25%       122.8
50%       360.0
75%       621.6
max       1790.4
Name: altitude, dtype: float64
```

3.3 Altitude × Temperatura Média e Pressão Média

Valida o gradiente altimétrico: temperatura deve cair $\sim 6.5^{\circ}\text{C}/\text{km}$ e pressão deve diminuir com altitude.

O que esperar: correlação negativa clara nos dois gráficos, com regressão linear decrescente.




3.4 Mapa do Brasil — Completude dos Dados por Estação

Cada ponto representa uma estação meteorológica. A cor indica o percentual médio de dados não-nulos: **verde = dados completos**, **amarelo = parcialmente incompleto**, **vermelho = crítico**.

O que esperar: regiões da Amazônia e Norte do Brasil com mais estações em vermelho, enquanto Sul e Sudeste tendem a ter melhor cobertura.

Completude dos Dados por Estação (%) — verde = completo · vermelho = incompleto




4. Análise Climatológica

Esta seção explora os padrões temporais e as relações entre as variáveis meteorológicas, incluindo sazonalidade, tendência de longo prazo, ciclo diurno e correlações.

4.1 Sazonalidade — Médias Mensais

Mostra como cada variável se comporta ao longo dos meses do ano, agregando toda a série histórica.

O que esperar: temperatura mais alta no verão austral (dez–fev), chuva concentrada no mesmo período, radiação solar com pico no verão, umidade inversamente correlacionada com a temperatura no inverno seco.




4.2 Tendência de Temperatura ao Longo do Tempo

Analisa a evolução da temperatura média anual de 2000 a 2025. Com 25 anos de dados cobrindo todo o Brasil, deve ser possível detectar o sinal de aquecimento climático na série histórica.

A regressão linear quantifica a taxa de mudança em °C/ano e o p-valor indica se a tendência é estatisticamente significativa ou pode ser atribuída ao acaso.

O que esperar: tendência positiva (aquecimento) com slope entre 0.01 e 0.05°C/ano, consistente com o aquecimento global observado no Brasil. p-valor < 0.05 confirma significância.




Variação total estimada : +0.24°C ao longo do período
 Slope : +0.0096°C/ano
 R^2 : 0.031
 p-valor : 0.3895 x não significativo

4.3 Ciclo Diurno — Médias por Hora UTC

Mostra como cada variável varia ao longo das 24 horas do dia (em UTC).

O que esperar: temperatura com pico entre 18–21 UTC (15–18 BRT, tarde), radiação solar zerando à noite, umidade com padrão inverso à temperatura.



Ciclo Diurno — Média por Hora UTC (todas as estações)



4.4 Distribuição de Chuva

A chuva tem distribuição muito diferente das outras variáveis: a maioria das horas é seca (rainfall = 0) e os eventos seguem distribuição exponencial ou gamma.

O que esperar: mais de 90% das horas com chuva zero. Eventos acima de 10 mm/h já são intensos.




Top 10 estações mais chuvosas (média mm/h):

	name	state	rainfall
	NOVA XAVANTINA	MT	1.113333
	ITANHANGA	MT	0.580608
	DIAMANTINO	MT	0.498824
	LUCAS DO RIO VERDE	MT	0.414583
	COCALINHO	MT	0.411905
	BELEM	PA	0.394574
	OIAPOQUE	AP	0.341101
	S. G. DA CACHOEIRA	AM	0.337583
	BOM JARDIM DA SERRA – MORRO DA IGREJA	SC	0.335247
	TERESOPOLIS–PARQUE NACIONAL	RJ	0.327917

4.5 Rosa dos Ventos

`wind_direction` é uma variável **circular** (0° e 360° são o mesmo ponto) e não pode ser analisada com histograma convencional — 359° e 1° estão a 2° de distância, não a 358°. A rosa dos ventos é a visualização correta: mostra a frequência de ocorrência por direção e a intensidade (cor) indica a velocidade média do vento naquela direção.

O que esperar: ventos predominantes do quadrante leste/nordeste no Brasil, influenciados pelos alísios. Variações regionais significativas entre litoral e interior.



Direção mais frequente : E (10.7%)
Velocidade média geral : 1.99 m/s

4.6 Extremos Históricos por Variável

Identifica o maior e menor valor já registrado em cada variável, com a estação e a data do evento.

O que esperar: temperatura máxima acima de 40°C no interior do Nordeste, mínimas abaixo de 0°C no Sul. Chuvas extremas próximas a 200–300 mm/h em eventos convectivos severos.

Temperatura (°C)

MAX 45.00 estação A053 em 2021-07-11
MIN -9.60 estação A861 em 2011-04-15

Umidade (%)

MAX 100.00 estação A101 em 2001-11-04
MIN 7.00 estação A923 em 2019-05-16

Chuva (mm)

MAX 138.20 estação A348 em 2022-05-20
MIN 0.00 estação A001 em 2000-05-07

Rajada (m/s)

MAX 50.00 estação A506 em 2025-08-06
MIN 0.00 estação A601 em 2000-08-20

Pressão (hPa)


MAX 1050.00 estação A604 em 2012-03-21
MIN 802.00 estação A845 em 2023-07-13

4.7 Matriz de Correlação Completa entre Variáveis

Mede o grau de associação linear entre todos os pares de variáveis meteorológicas. A diagonal principal sempre vale **1.0**. Cores quentes (vermelho) = correlação positiva forte; cores frias (azul) = correlação negativa forte.

O que esperar:

- `temperature` × `dew_point`: alta positiva (~0.85+)
- `temperature` × `humidity`: negativa moderada
- `wind_speed` × `wind_gust`: muito alta (~0.95+)
- `global_radiation` × `temperature`: positiva




4.8 Scatter Plots — Pares com Alta Correlação

Visualiza a relação entre os pares de variáveis mais correlacionados identificados na matriz acima. Permite confirmar se a relação é linear, verificar heteroscedasticidade e identificar agrupamentos.

O que esperar: `temperature` × `dew_point` com nuvem densa e bem alinhada. `wind_speed` × `wind_gust` com relação quase perfeita.

Correlação Visual entre Pares de Variáveis




5. Similaridade entre Estações

Esta seção analisa como as estações se relacionam entre si em termos de proximidade geográfica e similaridade climática — base para a escolha de estações proxy no gap-filling.

5.1 Correlação de Temperatura vs. Distância Efetiva

Valida a hipótese central do projeto: estações mais próximas em `effective_distance_km` devem ter temperaturas mais correlacionadas.


O que esperar: correlação decrescente com o aumento da distância efetiva. Pares abaixo de 50 km devem ter correlação acima de 0.90.



5.2 Correlação Média por Faixa de Distância Efetiva

Agrega os pares em faixas e mostra a correlação média por faixa. O ponto de inflexão define o raio ideal de busca de estações proxy.

O que esperar: queda progressiva estabilizando próxima de 0.5–0.6 para grandes distâncias.



5.3 Clustering de Estações por Perfil Climático


Agrupar as estações em clusters com base em suas médias históricas de temperatura, umidade, chuva, radiação e vento. Cada cluster representa um regime climático distinto.

O que esperar: clusters separando claramente Amazônia (quente e úmido), Nordeste semiárido (quente e seco), Sul (temperado), Cerrado e Mata Atlântica.

Perfil médio por cluster:

	temperature	humidity	rainfall	global_radiation	wind_speed	altitude
cluster						
0	19.0	78.0	0.2	726.9	2.5	557.7
1	26.0	67.5	0.1	865.3	2.4	271.0
2	23.4	68.4	0.1	798.2	2.0	530.9
3	26.1	78.1	0.2	759.1	1.3	150.9
4	25.3	71.8	0.2	2727.7	2.2	341.8

Clustering de Estações por Perfil Climático (K=5)



6. Exportar para PDF

Exporta este notebook para HTML e converte para PDF usando `weasyprint`. Execute esta célula após rodar todas as anteriores.

Pré-requisito: `pip install weasyprint`

Convertendo notebook para HTML...

HTML gerado: 1.3_exploratory_analysis.html

Convertendo HTML para PDF...

PDF gerado: 1.3_exploratory_analysis.pdf